

# Giancarlo Maldonado Cardenas

AI Engineer | Generative AI | Multi-Agent Systems

📍 Campinas, Brasil    ✉️ [maldonadogeek@gmail.com](mailto:maldonadogeek@gmail.com)    ☎️ +55 19 98972-7008

## PERFIL PROFISSIONAL

AI Engineer com Mestrado em Ciência da Computação pela UNICAMP e experiência no desenvolvimento de soluções de Inteligência Artificial Generativa, agentes inteligentes e arquiteturas multiagentes para ambientes corporativos.

Atuação no Instituto de Ciência e Tecnologia Itaú na concepção e implementação de mecanismos de descoberta, seleção, roteamento e orquestração de agentes, incluindo pipelines baseados em Large Language Models, recuperação de informação, Agent Cards, integração com APIs e protocolos de comunicação entre agentes. Desenvolvimento de mecanismo proprietário de *Hybrid Retrieval* que resultou em pedido de patente.

Experiência em Python, LLMs, RAG, bancos vetoriais, sistemas assíncronos, backend para IA, benchmarking e avaliação end-to-end, aliando pesquisa aplicada, engenharia de sistemas e desenvolvimento de soluções escaláveis orientadas a produtos e jornadas de negócio.

## COMPETÊNCIAS TÉCNICAS

- **Generative AI e Agentic AI:** Large Language Models (LLMs), agentes inteligentes, agentes especializados por domínio, tool calling, function calling, prompt engineering e integração de ferramentas.
- **Arquiteturas multiagentes:** detecção de intenção, roteamento de demandas, orquestração multiagente, descoberta dinâmica, Agent Cards, seleção Top-K, MCP e A2A.
- **RAG e bases de conhecimento:** Retrieval-Augmented Generation, *Dense Retrieval*, busca vetorial, BM25, recuperação léxica e semântica, *Weighted Reciprocal Rank Fusion* (WRRF) e ChromaDB.
- **Frameworks e plataformas de IA:** LangChain, LangGraph, CrewAI, Hugging Face, OpenAI, Azure OpenAI e AWS Bedrock.
- **Engenharia de software para IA:** Python, AsyncIO, FastAPI, Pytest, APIs REST, SDKs, serviços assíncronos e aplicações orientadas a serviços.
- **Dados e persistência:** bancos vetoriais, SQL, NoSQL, bancos relacionais, preparação de datasets, análise exploratória e processamento de dados.
- **Avaliação e eficiência de sistemas de IA:** benchmarking, estudos de ablação, Recall@K, MRR, acurácia end-to-end, análise de latência, custo, escalabilidade e robustez semântica.
- **Cloud e infraestrutura:** AWS, Azure, Docker, sistemas distribuídos.
- **Machine Learning:** modelos supervisionados, redes neurais, aprendizado federado, transfer learning, séries temporais e quantização de modelos.
- **Idiomas:** Espanhol nativo, Português fluente e Inglês avançado para leitura e interpretação de documentação e artigos técnicos.

## EXPERIÊNCIA PROFISSIONAL

**Pesquisador Bolsista em Inteligência Artificial (AI Engineer) | Instituto de Ciência e Tecnologia Itaú** 2025–Atual

- Pesquisa e desenvolvimento de arquiteturas para descoberta, roteamento, seleção e orquestração de agentes inteligentes em ecossistemas multiagentes de larga escala.
- Desenvolvimento de infraestrutura end-to-end composta por processamento da consulta do usuário, recuperação de agentes candidatos, construção de pool Top-K e decisão final por um *LLM Orchestrator*.
- Desenvolvimento de agentes e protótipos multiagentes em Python, integrando Large Language Models, ferramentas, APIs, Agent Cards e mecanismos de delegação de tarefas.

- Concepção de mecanismo proprietário de *Hybrid Retrieval* baseado em *Dense Retrieval*, BM25 e *Weighted Reciprocal Rank Fusion (WRRF)*, trabalho que resultou em pedido de patente.
- Evolução da solução para uma SDK modular de descoberta e orquestração, separando recuperação, raciocínio da LLM, governança e execução dos agentes.
- Pesquisa e prototipação com Model Context Protocol (MCP) e Agent-to-Agent Protocol (A2A), considerando interoperabilidade, descoberta dinâmica, segurança e integração com sistemas corporativos.
- Desenvolvimento de ambiente de benchmarking em Python, Streamlit e ChromaDB para avaliação de recuperação, acurácia, latência, custo de inferência, escalabilidade e robustez.
- Validação da arquitetura utilizando dados sintéticos e o benchmark MS MARCO, com aproximadamente 620 mil documentos e 79 mil consultas.
- Avaliação end-to-end em cenários contendo de 100 a 5.000 agentes, mantendo acurácia entre 92% e 93,5% com pool fixo de dez candidatos.
- Redução aproximada de 99,8% no volume de tokens e no custo de inferência, além da redução do tempo de execução de 3,9 horas para cerca de nove minutos no cenário de maior escala.
- Desenvolvimento de experimentos controlados para análise de vieses de posição, rótulo, marca e formato em decisões realizadas por modelos de linguagem.
- Revisão de literatura, análise de frameworks, elaboração de documentação técnica e apresentação de resultados para equipes multidisciplinares.

#### **Pesquisador de IA | Viva Bem – Samsung/UNICAMP**

2022–2024

- Desenvolvimento de soluções de Inteligência Artificial aplicadas a dados sensoriais e biométricos provenientes de dispositivos móveis e vestíveis.
- Processamento de grandes volumes de séries temporais e desenvolvimento de estratégias customizadas de extração e engenharia de atributos.
- Desenvolvimento e avaliação de redes neurais CNN-1D para classificação e reconhecimento de atividades humanas.
- Implementação de sistemas de aprendizado federado, com foco em treinamento distribuído, descentralização e privacidade dos dados.
- Aplicação de quantização com TensorFlow Lite para otimização de modelos e redução do custo de inferência.
- Colaboração em equipe multidisciplinar de pesquisa aplicada, desde a experimentação até a validação científica dos resultados.

#### **Pesquisador de Mestrado | UNICAMP**

2019–2025

- Desenvolvimento de pesquisa em detecção de colisões e priorização do acesso aleatório em redes celulares mMTC/5G.
- Desenvolvimento e comparação de modelos baseados em Logistic Regression, SVM, Decision Trees, Random Forest, Naive Bayes, KNN, LightGBM, XGBoost e redes neurais.
- Desenvolvimento de pipelines experimentais para treinamento, validação e análise comparativa de modelos de Machine Learning.
- Simulação de sistemas celulares e cenários de acesso aleatório utilizando MATLAB e ferramentas para redes LTE/5G.
- Análise de sistemas distribuídos, sinais de baixa latência, escalabilidade e comunicação em ambientes com grande volume de dispositivos.

#### **Estagiário de Docência | Instituto de Computação – UNICAMP**

2020

- Suporte didático e técnico a estudantes de Ciência da Computação.
- Apoio em atividades práticas, projetos, exercícios e resolução de dúvidas técnicas.

#### **Administrador de Redes | Ministério Público – Fiscalía de la Nación, Peru**

2018

- Administração de redes, servidores e infraestrutura de TI em escala nacional.
- Implementação de melhorias de infraestrutura e suporte a sistemas corporativos.

- Administrador de Redes | Universidad Nacional de San Martín, Peru** 2014–2018
- Administração de redes, telecomunicações, fibra óptica, servidores e infraestrutura de data center.
  - Configuração de Active Directory, sistemas de segurança e firewalls.
- Analista Web | Servicio de Administración Tributaria, Peru** 2012
- Suporte a redes, bancos de dados e sistemas corporativos.
  - Desenvolvimento de soluções de TI para melhoria de processos internos.
- Administrador de Redes | G&M Network, Peru** 2008–2012
- Estruturação de redes, configuração de roteadores e criação de máquinas virtuais.
  - Suporte técnico e treinamento de usuários e equipes.

## FORMAÇÃO ACADÊMICA

---

**Mestrado em Ciência da Computação** 2025  
Universidade Estadual de Campinas – UNICAMP, Campinas, Brasil

**Engenharia de Sistemas** 2012  
Universidad César Vallejo, Tarapoto, Peru

## PROJETOS E RESULTADOS SELECIONADOS

---

- **Plataforma de descoberta e orquestração multiagente:** arquitetura modular para seleção, roteamento e delegação de tarefas entre agentes inteligentes, com suporte a MCP, A2A e decisão baseada em LLMs.
- **Hybrid Retrieval para agentes inteligentes:** mecanismo proprietário baseado em *Dense Retrieval*, BM25 e WRRF, validado em larga escala e associado a pedido de patente.
- **Avaliação de sistemas de IA Generativa:** benchmarks end-to-end de acurácia, recuperação, custo, tokens, latência, escalabilidade e vieses de modelos de linguagem.
- **Machine Learning e inferência eficiente:** aprendizado federado aplicado à saúde digital, redes neurais para séries temporais e quantização de modelos com TensorFlow Lite.

## INFORMAÇÕES ADICIONAIS

---

- Disponibilidade para atuação híbrida em São Paulo, mudança e viagens.
- Experiência em pesquisa aplicada, prototipação, benchmarking, apresentação técnica e colaboração com equipes multidisciplinares.
- Atuação direcionada a AI Engineering, Generative AI, plataformas de agentes, LLMOps e sistemas multiagentes.
- Carteira Nacional de Habilitação.